

# Analyse des performances académiques des étudiants

---

## 1. Méthodologie

### 1.1 Objectif de l'étude

Cette étude vise à analyser l'impact de certaines habitudes quotidiennes sur les performances académiques d'un groupe d'étudiants. Le but est d'identifier les facteurs les plus influents sur le score aux examens.

### 1.2 Données

La base de données a été importée à partir de kaggle. Elle comprend des informations sur :

- exam\_score : score obtenu à l'examen
- study\_hours\_per\_day : nombre d'heures d'étude par jour
- attendance\_percentage : pourcentage de présence aux cours
- social\_media\_hours : temps passé sur les réseaux sociaux
- sleep\_hours : durée moyenne du sommeil par jour
- exercise\_frequency : fréquence d'activité physique

### 1.3 Traitement des données

- Suppression des colonnes non analytiques (age, student\_id, gender, netflix\_hours, part\_time\_job, parental\_education\_level, internet\_quality, diet\_quality, mental\_health\_rating, extracurricular\_participation)
- Analyse descriptive avec les bibliothèques `psych` et `summary`
- Visualisation (histogrammes, boxplots, nuages de points)
- Modélisation (régressions linéaires simples et multiples)
- Tests statistiques (normalité, hétéroscédasticité, autocorrélation)

## 2. Résultats

### 2.1 Analyse descriptive

Les statistiques de base montrent une grande variabilité dans les habitudes. La moyenne du score à l'examen est de 69.60. Les étudiants étudient en moyenne 3-4 heures par jour et dorment entre 6 et 8 heures.


### 2.2 Corrélations

Les coefficients de corrélation montrent que:


- study\_hours\_per\_day (**0.82**) est fortement corrélé à exam\_score
- attendance\_percentage (**0.089**) a aussi un effet positif
- social\_media\_hours (**-0.16**) est négativement corrélé
- Les autres variables (sleep\_hours (**0.12**) et exercise\_frequency (**0.16**)) ont un impact plus faible


### 2.3 Visualisation

**Graphique 1:** Matrice de graphiques en nuage de points avec la fonction (pairs)




**Graphique 2** : Les histogrammes







**Graphique 3:** Linéarité entre deux variables explicatives




**Graphique 4:** Boxplots des variables




**Graphique 5:** Relation entre heures d'étude et score d'examen




**Graphique 6:** Relation entre fréquence de présence et score d'examen




**Graphique 7:** Relation entre temps passé sur les réseaux sociaux et score d'examen



**Graphique 8:** Relation entre durée moyenne et score d'examen



**Graphique 9:** Relation entre fréquence d'activité physique et score d'examen



## 2.4 Modélisation et résultats

### Modèle 1: Heures d'étude et Score d'examen

- **Formule:**  $\text{exam\_score} \sim \text{study\_hours\_per\_day}$
- **Résumé du modèle :**
  - Le **coefficient de l'intercept** (36.18) signifie qu'avec zéro heure d'étude par jour, le score d'examen moyen est de 36.18.
  - **Heures d'étude par jour :** Le coefficient de 9.40 montre qu'avec chaque heure supplémentaire d'étude par jour, le score d'examen augmente de 9.40 points en moyenne.
  - **P-value :** Le test de significativité indique que les résultats sont hautement significatifs ( $p\text{-value} < 2e-16$ ), ce qui signifie que l'effet des heures d'étude sur le score d'examen est statistiquement significatif.
  - **R<sup>2</sup> ajusté** = 0.673, ce qui suggère que le modèle explique environ 67.3% de la variance du score d'examen.

### Modèle 2: Fréquence de présence et Score d'examen

- **Formule:**  $\text{exam\_score} \sim \text{attendance\_percentage}$
- **Résumé du modèle :**
  - **L'intercept** est de 58.33, ce qui représente le score d'examen moyen avec une présence de 0%.
  - **Fréquence de présence :** Le coefficient de 0.13 indique qu'une augmentation d'un pourcentage de présence est associée à une augmentation de 0.13 point du score d'examen.
  - **P-value :** La p-value de 0.0375 montre que la fréquence de présence est significativement liée au score d'examen.

- **R<sup>2</sup> ajusté** = 0.0042, ce qui indique que la fréquence de présence seule explique très peu de la variation du score d'examen.

### Modèle 3: Heures passées sur les réseaux sociaux et Score d'examen

- **Formule:** exam\_score ~ social\_media\_hours
- **Résumé du modèle :**
  - **Intercept** : 74.62, indiquant que, en l'absence d'heures passées sur les réseaux sociaux, le score moyen est de 74.62.
  - **Heures passées sur les réseaux sociaux** : Le coefficient de -2.13 suggère que chaque heure supplémentaire passée sur les réseaux sociaux diminue le score d'examen de 2.13 points en moyenne.
  - **P-value** : La p-value de 1.68e-05 montre que l'effet est très significatif.
  - **R<sup>2</sup> ajusté** = 0.0217, ce qui suggère que les heures passées sur les réseaux sociaux expliquent environ 2.17% de la variance du score d'examen

### Modèle 4: Heures de sommeil et Score d'examen

- **Formule:** exam\_score ~ sleep\_hours
- **Résumé du modèle :**
  - **Intercept** : 58.86, indiquant un score moyen de 58.86 si un étudiant dort zéro heure.
  - **Heures de sommeil** : Chaque heure de sommeil supplémentaire est associée à une augmentation de 1.63 points du score d'examen.
  - **P-value** : La p-value de 0.000569 montre que cet effet est statistiquement significatif.
  - **R<sup>2</sup> ajusté** = 0.0135, indiquant que les heures de sommeil expliquent seulement 1.35% de la variance du score d'examen.

### Modèle 5: Fréquence d'exercice et Score d'examen

- **Formule:** exam\_score ~ exercise\_frequency
- **Résumé du modèle :**
  - **Intercept** : 65.37, indiquant un score moyen de 65.37 pour une fréquence d'exercice de zéro.
  - **Fréquence d'exercice** : Le coefficient de 1.31 signifie qu'une augmentation de la fréquence d'exercice est associée à une augmentation de 1.31 points du score d'examen.
  - **P-value** : La p-value de 7.15e-06 montre que l'effet est très significatif.
  - **R<sup>2</sup> ajusté** = 0.0237, ce qui montre que la fréquence d'exercice explique environ 2.37% de la variation du score d'examen.

### Model\_full : Régression linéaire multiple avec toutes les variables

- **Formule:** exam\_score ~ study\_hours\_per\_day + attendance\_percentage + sleep\_hours + social\_media\_hours + exercise\_frequency
- **Résumé du modèle :**
  - **Intercept** : 15.45
  - **Heures d'étude** : Coefficient de 9.59, indiquant que l'augmentation des heures d'étude par jour est le facteur le plus fort influençant le score d'examen.

- **Fréquence de présence** : Coefficient de 0.12, une augmentation de la fréquence de présence par un pourcentage est associée à une légère augmentation du score d'examen.
- **Heures de sommeil** : Coefficient de 1.88, chaque heure supplémentaire de sommeil augmente le score d'examen de 1.88 points.
- **Réseaux sociaux** : Coefficient de -2.61, chaque heure supplémentaire passée sur les réseaux sociaux est associée à une diminution du score.
- **Exercice physique** : Coefficient de 1.51, chaque augmentation de la fréquence d'exercice augmente le score d'examen.
- **P-values** : Toutes les variables sont significativement associées au score d'examen ( $p\text{-value} < 0.05$ ).
- **R<sup>2</sup> ajusté** = 0.7649, ce qui signifie que ce modèle multiple explique environ 76.49% de la variance dans le score d'examen.

### Modèle 6 : Régression linéaire multiple avec study\_hours\_per\_day et attendance\_percentage

- **Formule:** exam\_score ~ study\_hours\_per\_day + attendance\_percentage
- **Résumé du modèle :**
  - **Intercept** : 27.367 : La note moyenne estimée pour un étudiant qui ne travaille pas et qui a 0 % de présence
  - **study\_hours\_per\_day** = 9.385 ( $p < 2e-16$ ) : Chaque heure d'étude supplémentaire par jour est associée à une augmentation moyenne de 9.39 points au score d'examen.
  - **attendance\_percentage** = 0.105 ( $p = 0.00341$ ) : Chaque point de pourcentage supplémentaire de présence est associé à une augmentation moyenne de 0.11 point au score d'examen.
  - **R<sup>2</sup> ajusté** = 0.676 → 67.6 % de la variabilité des scores est expliquée par ces deux variables.
  - **F-statistic** = 834.8,  $p\text{-value} < 2.2e-16$  → Le modèle est globalement très significatif.

### Test de Multicolinéarité (VIF)

- Tous les VIF sont proches de 1 donc pas de colinéarité
- study\_hours\_per\_day = 1.004
- social\_media = 1.008
- attendance\_percentage = 1.002
- Sleep\_hours = 1.003
- Exercise\_frequency = 1.005



- But : Comparer la qualité des modèles ajustés (plus bas = meilleur).
- Résultat :
  - model6 : AIC = 5872.685, df = 4
  - model\_full : AIC = 5619.258, df = 7
- Interprétation : model\_full a un AIC beaucoup plus faible → il est nettement préférable à model du point de vue du compromis entre ajustement et complexité

### Shapiro test

Normalité des résidus

- $W = 0.99688$ , p-value = 0.1229
- Résidus normalement distribués ( $p > 0.05$ ) → condition respectée pour les tests paramétriques.

### DWTEST(model\_full) DURBIN WATSON TEST

- Résultat :
  - $DW = 1.8338$ , p-value = 0,0095
- Interprétation :
  - p-value < 0.05 : présence d'autocorrélation positive des résidus.
  - Cela viole l'hypothèse d'indépendance des erreurs, ce qui est critique surtout pour les données temporelles.

### BPTEST(model\_full) BREUSCH-PAGAN TEST

- Résultat :
  - $BP = 14.022$ , df = 5, p-value = 0.01547
- Interprétation :
  - p-value < 0.05 → présence d'hétéroscédasticité.
  - Les variances des erreurs ne sont pas constantes → cela peut biaiser les erreurs standards, donc les tests de significativité.

### Résumé des tests

| Condition        | Test          | Résultat    | Statut    |
|------------------|---------------|-------------|-----------|
| Normalité        | Shapiro-Wilk  | p = 0.1229  | ✅ OK      |
| Homoscédasticité | Breusch-Pagan | p = 0.01547 | ⚠️ Violée |
| Indépendance     | Durbin-Watson | p = 0.009   | ⚠️ Violée |

## Discussion

| Diagnostic            | Test          | Résultat    | Conclusion                 |
|-----------------------|---------------|-------------|----------------------------|
| Normalité des résidus | Shapiro-Wilk  | p = 0.1229  | ✅ OK                       |
| Homoscedasticité      | Breusch-Pagan | p = 0.01547 | ❌ Variance non constante   |
| Autocorrélation       | Durbin-Watson | p = 0.009   | ❌ Autocorrélation présente |
| Multicolinéarité      | VIF           | tous < 1.01 | ✅ Pas de souci             |

## Correction robuste de type Newey-West

| Variable              | Estimation | p-value       | Interprétation                          |
|-----------------------|------------|---------------|-----------------------------------------|
| (Intercept)           | 15.45      | 1.899e-06 *** | Intercept significatif.                 |
| study_hours_per_day   | 9.59       | < 2.2e-16 *** | Très fortement positif et significatif. |
| attendance_percentage | 0.116      | 0.00017 ***   | Positif et significatif.                |
| sleep_hours           | 1.88       | 2.07e-15 ***  | Significatif.                           |
| social_media_hours    | -2.61      | < 2.2e-16 *** | Effet négatif et très significatif.     |
| exercise_frequency    | 1.51       | < 2.2e-16 *** | Effet positif significatif.             |

Toutes les variables sont statistiquement significatives, même après correction robuste, ce qui renforce la fiabilité des effets observés malgré la présence détectée d'hétéroscédasticité (Breusch-Pagan test) et d'autocorrélation (Durbin-Watson test).

## Discussion

- Null deviance : 221306 → déviation totale sans aucune variable
- Residual deviance : 51705 → déviation expliquée par le modèle
- Réduction importante, donc le modèle explique bien la variabilité.
- AIC = 5619.3 → utile pour comparer avec d'autres modèles (plus bas = meilleur)
- Conclusion du modèle:
  - Statistiquement solide face aux problèmes de variance non constante (hétéroscédasticité).
  - Fiable même en présence d'autocorrélation des résidus.

## AJUSTEMENT DU MODELE

| Variable              | Coefficient | Std. Error | t-value | p-value  | Signification |
|-----------------------|-------------|------------|---------|----------|---------------|
| (Intercept)           | 15.45       | 3.10       | 4.98    | 7.77e-07 | ***           |
| study_hours_per_day   | 9.59        | 0.20       | 48.73   | < 2e-16  | ***           |
| attendance_percentage | 0.12        | 0.03       | 3.81    | 0.000152 | ***           |
| sleep_hours           | 1.88        | 0.23       | 8.20    | 9.99e-16 | ***           |
| social_media_hours    | -2.61       | 0.24       | -10.80  | < 2e-16  | ***           |
| exercise_frequency    | 1.51        | 0.14       | 10.64   | < 2e-16  | ***           |

Interprétation :

- Toutes les variables sont hautement significatives ( $p < 0.001$ ).
- Les coefficients sont interprétés comme suit :
  - +9.59 pour study\_hours\_per\_day → chaque heure supplémentaire d'étude augmente le score d'examen de 9.6 points environ.
  - +0.12 pour attendance\_percentage → chaque point de pourcentage de présence augmente légèrement le score.
  - +1.88 pour sleep\_hours → plus de sommeil est bénéfique.
  - -2.61 pour social\_media\_hours → chaque heure passée sur les réseaux sociaux réduit fortement le score.
  - +1.51 pour exercise\_frequency → faire du sport aide aussi.

## **3. Discussion**

Les résultats confirment que les heures d'étude et la présence en cours sont les principaux déterminants de la performance. L'usage excessif des réseaux sociaux semble avoir un effet négatif, mais non décisif. Le sommeil et l'activité physique n'ont pas d'effet clairement mesurable dans ce modèle. Les limites incluent l'auto-déclaration des données, l'absence de certaines variables psychologiques (motivation, stress), et la non-prise en compte du temps (analyse transversale).

## 4. Conclusion

Les performances académiques sont influencées principalement par les heures d'étude quotidiennes et la fréquence de présence aux cours. Ces résultats soulignent l'importance de favoriser des habitudes d'apprentissage rigoureuses et un engagement scolaire constant. Cette analyse pourrait orienter les politiques éducatives et les programmes de soutien aux étudiants.

## 5. Annexe : Code R utilisé

### #répertoire de travail

```
setwd("C:/Users/Sira Dia/OneDrive/Desktop/Langage R/Projet_patrice_sira")
getwd()
```

### #importation de la base de données

```
data = student_habits_performance
View(data)
head(data)
```

### #analyse descriptive

```
install.packages("psych")
library(psych)
```

```
students = subset(data, select = -c(age, student_id, gender, netflix_hours, part_time_job, netflix_hours,
parental_education_level, internet_quality, diet_quality, mental_health_rating, extracurricular_participation))
```

```
View(students)
describe(students)
summary(students)
```

### #faire la liaison de deux variables

```
pairs(students)
attach(students)
```

### #visualisation : histogramme

```
par(mfrow = c(2,2))
hist(exam_score, main="Histogram of exam_score", xlab="Exam score", col="gray", proba =T, nclass = 50)
lines(density(exam_score))
```

```
hist(study_hours_per_day, main="Histogram of study_hours/day", xlab="Study hours per day", col="lightblue",proba
=T, nclass = 50)
lines(density(study_hours_per_day))
```

```
hist(social_media_hours, main="Histogram of social_media_hours", xlab="Social_media_hours", col="lightgreen",
proba =T, nclass = 50)
lines(density(social_media_hours))
```

```
hist(attendance_percentage, main="Histogram of attendance_percentage", xlab="Attendance_percentage", col="red",
proba =T, nclass = 50)
lines(density(attendance_percentage))
```

```
hist(sleep_hours, main="Histogram of sleep_hours", xlab="Sleep_hours", col="pink", proba =T, nclass = 50)
lines(density(sleep_hours))
```

```
hist(exercise_frequency, main="Histogram of exercise_frequency", xlab="Exercise_frequency", col="brown", proba
=T, nclass = 50)
lines(density(exercise_frequency))
```

#### **#Voir la linéarité entre les deux variables explicatives**

```
par(mfrow=c(1,5))
plot(x=study_hours_per_day, y=exam_score, main = "exam_score~study_hours/day")
abline(lm(exam_score~study_hours_per_days), col=1)
```

```
plot(x=social_media_hours, y=exam_score, main = "exam_scoresocial_media_hours")
abline(lm(exam_scoresocial_media_hours), col=3)
```

```
plot(x=attendance_percentage, y=exam_score, main = "exam_scoreattendance_percentage")
abline(lm(exam_scoreattendance_percentage), col=1)
```

```
plot(x=sleep_hours, y=exam_score, main = "exam_scoresleep_hours")
abline(lm(exam_scoresleep_hours), col=1)
```

```
plot(x=exercise_frequency, y=exam_score, main = "exam_scoreexercise_frequency")
abline(lm(exam_scoreexercise_frequency), col=1)
```

#### **#corrélation**

```
cor(study_hours_per_day,exam_score)
cor(social_media_hours,exam_score)
cor(attendance_percentage, exam_score)
cor(sleep_hours, exam_score)
cor(exercise_frequency, exam_score)
```

#### **#table de corrélation complète**

```
cor_matrix = cor(students)
cor_matrix
```

#### **#boxplot**

```
par(mfrow=c(1,5))
boxplot(study_hours_per_day,main="study_hours/day")
boxplot(social_media_hours,main="social_media")
boxplot(attendance_percentage,main="attendance%")
boxplot(sleep_hours,main="sleep_hours")
boxplot(exercise_frequency,main="exercise_frequency")
```

#### **#divise notre base**

```
set.seed(101)
sample=sample.int(n=nrow(students), size= floor(.80*nrow(students)), replace=F)
train=students[sample,]
test=students[-sample,]
```

#### **#estimation de modèle simple**

```
model1=lm(exam_score~study_hours_per_day, data=train)
summary(model1)
model2 = lm(exam_score ~ attendance_percentage, data=train)
```

```
summary(model2)
model3 = lm(exam_score ~ social_media_hours, data=train)
summary(model3)
model4 = lm(exam_score ~ sleep_hours, data=train)
summary(model4)
model5 = lm(exam_score ~ exercise_frequency, data=train)
summary(model5)
```

#### **#régression linéaire multiple**

```
model_full = lm(exam_score ~ study_hours_per_day + attendance_percentage + sleep_hours + social_media_hours +
exercise_frequency, data=train)
summary(model_full)
model6 = lm(exam_score ~ study_hours_per_day + attendance_percentage, data=train)
summary(model6)
```

#### **#test de la normalité des résidus**

```
shapiro.test(residuals(model2))
```

```
install.packages("lmtest")
library(lmtest)
```

#### **#fiabilité du model**

```
bptest(model1)
dwtest(model1)
```

#### **#visualisation avec ggplot2**

```
install.packages("ggplot2")
library(ggplot2)
```

```
ggplot(students, aes(x=study_hours_per_day, y=exam_score)) + geom_point(color="blue") +
geom_smooth(method="lm", col="red") + labs(title="Relation entre heures d'étude et score d'examen", x="Heures
d'étude", y="Score d'examen")
```

```
ggplot(students, aes(x=attendance_percentage, y=exam_score)) + geom_point(color="blue") +
geom_smooth(method="lm", col="red") + labs(title="Relation entre fréquence de présence et score d'examen",
x="Fréquence de présence ", y="Score d'examen")
```

```
ggplot(students, aes(x=social_media_hours, y=exam_score)) + geom_point(color="blue") + geom_smooth(method="lm",
col="red") + labs(title="Relation entre temps passé sur les réseaux sociaux et score d'examen", x="Temps passé sur les
réseaux sociaux ", y="Score d'examen")
```

```
ggplot(students, aes(x=sleep_hours, y=exam_score)) + geom_point(color="blue") + geom_smooth(method="lm",
col="red") + labs(title="Relation entre durée moyenne du sommeil et score d'examen", x="Durée moyenne du sommeil par
jour", y="Score d'examen")
```

```
ggplot(students, aes(x=exercise_frequency, y=exam_score)) + geom_point(color="blue") + geom_smooth(method="lm",
col="red") + labs(title="Relation entre fréquence d'activité physique et score d'examen", x="Fréquence d'activité physique",
y="Score d'examen")
```

```
install.packages("car")
library(car)
```

```
vif(model_full) # VIF > 5 ou 10 = multicolinéarité possible
```

**#ajustement du modèle**

```
model_final = glm(exam_score ~ study_hours_per_day +  
attendance_percentage + sleep_hours + social_media_hours  
+ exercise_frequency, data=train)  
summary(model_final)
```

**#voir le modèle le plus performant**

```
AIC(model_full, model6)
```

**#Charger les bons packages**

```
library(lmtest)  
install.packages("sandwich")  
library(sandwich)
```

**#Appliquer une variance-covariance robuste à l'hétéroscédasticité et à l'autocorrelation**

```
vcov_hac = NeweyWest(model_full, lag = 1, prewhite = FALSE)
```

**#Recalculer les tests des coefficients avec cette matrice robuste**

```
coeftest(model_full, vcov = vcov_hac)
```